


隱道 Veilway

所有 AI 請求都走同一條道：送出前在平台內把個資換成代號，回覆回來後再換回真名。外部模型從頭到尾只看得到代號。

v2 (2026-10-07)：出口改走 PrivateLink、補上推論位置的查證結果、檢查點處理規則，以及特殊合規租戶的建議；隱道閘道改為獨立的 ECS service。


全景：隱道在系統中的位置

前台、業務 API、資料庫都是標準配置。整套架構跟一般 SaaS 不同的地方，在於後端唯一能連到平台外模型的出口，就是隱道閘道；它是獨立的 service，有自己的 security group 與 IAM role。



一次請求怎麼走過隱道

以文件中的例子示範：使用者輸入含有人名和地點的句子，Claude 收到的只有代號，回覆也是代號，最後由平台換回真名。



對照表從不離開平台，所以外部模型就算保留了請求內容，也無法把代號對回真人。每次實際送出的遮蔽後內容，以及實際推論位置 (usage.inference_geo)，會寫進 AI_REQUEST_LOG 作為稽核紀錄。影像、錄音和間接識別資訊的遮蔽方式還待設計。

隱道的元件

位置	中文名	英文名	做法
獨立的 ECS service	隱道開道	Veilway Gateway	統一介面 (IChatClient)，遮蔽、檢查、還原、計量各為一層 DelegatingChatClient；唯一能連到平台外模型的出口，有自己的 security group 與 IAM role
去程第一步	遮蔽器	Veil Masker	三層：① 正規表示式 (身分證、電話、Email、卡號、統編) ② 租戶字典 (客戶名單、員工名冊) ③ CPU 可跑的繁中 NER (人名、地址、公司名)；另做別名展開：王小明 → 小明、王先生
平台資料庫	對照表	Veil Map	真名與代號的對應，只存在平台內 (RDS，以租戶的 KMS key 加密)。預設每個對話一張並設 TTL；RAG 才用租戶範圍；絕不跨租戶
跨越邊界前	檢查點	Veil Check	送出前比對對照表原值、重跑正規表示式、比對租戶字典；處理規則見下一節
回程	還原器	Unveiler	讀取對照表，把回覆中的代號換回真名；容許模型改寫代號格式，串流時用緩衝區處理被切開的代號

位置	中文名	英文名	做法
通往租戶機房	隱道連接器	Veilway Connector	接 Ollama／vLLM 等 OpenAI 相容端點，切換只需改 endpoint；有特殊合規要求的租戶走這條

檢查點：攔下之後怎麼辦

檢查點掃描「準備送出的最終文字」，檢查三件事：對照表裡已登記的原值又出現了、格式固定的個資漏網、租戶字典裡的名字出現了。

情況	處理
對照表裡的原值沒換掉	自動補遮後重送，使用者不會感覺到
高信心命中（身分證、卡號）	自動補遮；補遮後仍命中就 fail-closed ，拒絕送出
低信心命中（如「林立」）	依租戶政策：嚴格的租戶直接拒絕；一般租戶讓使用者勾選「這不是個資」後送出，並記下這次放行
檢查點故障或逾時	一律 fail-closed ，不能因為檢查服務壞了就放行

限制：NER 第一次沒認出來的名字，檢查點多半也認不出來。檢查點防的是程式出錯，不是第二層 NER。每次攔截都寫入稽核紀錄（類型與處理方式），但**不記錄命中的原文**。

出口與推論位置

以下依 Anthropic 官方文件查證（2026-10）。

項目	結果
VPC endpoint	支援 AWS PrivateLink。閘道經 VPC endpoint 連線，endpoint 的 security group 與 policy 只允許閘道，呼叫權限只授權給閘道的 IAM role
區域	所有 AWS 商用區域皆可用；workspace 建在台北區域，只能從台北端點存取
推論位置	inference_geo 只有 global（預設，全球任一 Anthropic 資料中心）與 us（只在美國，價格 1.1 倍）； 沒有台灣或亞太選項
AWS 區域的作用	只決定端點與 IAM、CloudTrail、帳單的範圍， 不決定推論在哪裡
資料保存位置	不可設定，目前為 us
資料處理者	Anthropic；保留政策同第一方 API，零資料保留（ZDR）需另外申請

結論：端點在台北，推論與保存在境外。這正是隱道要解決的問題：出境的只有代號，對照表留在台北。對外說法統一為「平台在台灣，只有代號化後的內容出境」，不說「資料都在台灣」。代號化屬於假名化，仍算個人資料，服務條款與租戶合約需揭露推論位置與資料處理者。

有特殊合規要求的租戶：建議自建地端 AI

租戶若要求資料（即使已代號化）不得出境、推論必須在特定地點或處理者的設施內進行，或受主管機關對委外與跨境傳輸的限制（例如金融、醫療、公部門），平台不提供境外模型，而是建議租戶在自己的機房架設地端 AI，平台經隱道連接器接過去。

為什麼這樣建議

- 1. **只有地端能完全做到資料不出境**。推論位置只有 global 與 us，沒有台灣選項；對最嚴格的租戶，代號出境本身就可能不被接受。
- 2. **不涉及第三方資料處理者**。地端由租戶自己營運，不需另簽資料處理協議或評估跨境傳輸。
- 3. **不必另外維護第二條雲端路徑**。改走 Bedrock 也是選項，但要多維護一套模型 ID 與功能差異，而且仍在租戶的控制之外。
- 4. **架構已經預留**。隱道連接器只需改 endpoint，依路由政策導向地端，業務程式碼不必修改。
- 5. **回答品質可以更好**。模型在租戶機房時，可依租戶政策不做遮蔽，模型看得到完整上下文。

取捨（要先講清楚）：地端模型能力通常不如 Claude；GPU、維運與更新由租戶負責；平台只保證連接器與路由的正確性。

建置三階段

階段	內容	完成時能做到
1 • 骨架	VPC、IaC、CI/CD、CloudFront+WAF、S3 前台、ALB、C# API、Cognito、RDS 基本資料表（含 RLS）	能登入，前台呼叫 API，依租戶讀寫資料
2 • 隱道	隱道閘道（獨立 service）、Claude Platform on AWS（PrivateLink）、出口管控（egress proxy）、對照表／對話／稽核／計量存 RDS、Ollama 開發用	能多輪對話，外部只看得到代號
3 • 檔案與非同步	S3 上傳、SQS+Worker、文件解析與遮蔽、影音處理；可選：RAG、Batch、租戶地端連接器	上傳文件請 AI 分析，耗時工作不卡住 API

依據「AI-前後台架構 總結」（2026-10-06）繪製；線上模型已改為 Claude Platform on AWS，並依 Anthropic 官方文件查證出口與推論位置（2026-10-07）。參考：[Claude Platform on AWS](#)、[Data residency](#)。